# "People Analytics & Link Prediction: Ανίχνευση Κρυφών Συνεργασιών στο Εταιρικό Δίκτυο της Enron"

Πανεπιστήμιο Πειραιώς
Σχολή Τεχνολογιών Πληροφορικής Και Επικοινωνιών
Τμήμα Ψηφιακών Συστημάτων

Π.Μ.Σ.
“Πληροφοριακα Συστηματα & Υπηρεσιες”

Αθήνα
Ιούνιος 2026

# Περιεχόμενα


1. Εισαγωγή ..... 1
   1.1. Περιγραφή Προβλήματος ..... 1
2. Περιγραφή και Χαρακτηριστικά Δεδομένων ..... 1
   2.1. Επιλογή και Περιγραφή Δεδομένων ..... 1
3. Εξερευνητική Ανάλυση Δικτύου (Exploratory Data Analysis) ..... 2
   3.1. Μακροσκοπική Δομή και Ταχύτητα Διάδοσης ..... 2
   3.2. Συσταδοποίηση και Συνεργασία ..... 3
   3.3. Κατανομή Βαθμού (Degree Distribution) ..... 4
   3.4. Μέτρα Κεντρικότητας (Centrality Measures) ..... 5
4. Μεθοδολογία Πρόβλεψης Συνδέσμων ..... 7
   4.1. Δημιουργία Θετικών Δειγμάτων (Label 1) ..... 7
   4.2. Δημιουργία Αρνητικών Δειγμάτων (Label 0) ..... 7
   4.3. Ο Γράφος Εκπαίδευσης (Training Graph) ..... 7
   4.4. Μέθοδοι Πρόβλεψης Συνδέσμων (Link Prediction Methods) ..... 8
      4.4.1. Τοπολογικές Μέθοδοι Βασισμένες στη Γειτονιά (Neighborhood-based Metrics) 8
         4.4.1.1. Συντελεστής Jaccard (Jaccard Coefficient) ..... 8
         4.4.1.2. Δείκτης Adamic-Adar (Adamic-Adar Index) ..... 9
      4.4.2. Προχωρημένες Μέθοδοι - Εκμάθηση Αναπαραστάσεων (Representation Learning) ..... 9
         4.4.2.1. Embeddings με τη χρήση του αλγορίθμου Node2Vec ..... 9
         4.4.2.2. Περιγραφή Μεθοδολογίας Node2Vec και Ταξινόμησης ..... 10
   4.5. Εργαλεία και Περιβάλλον Υλοποίησης ..... 11
5. Πειραματική Αξιολόγηση ..... 11
   5.1. Μετρικές Αξιολόγησης ..... 11
   5.2. Ανάλυση Πειραμάτων ..... 12
      5.2.1. Υπερπαραμέτροι Node2Vec ..... 12
      5.2.2. Συγκριτική Αξιολόγηση Μοντέλων ..... 13
      5.2.3. Καμπύλη ROC (Receiver Operating Characteristic) ..... 14
      5.2.4. Έλεγχος Υπερεκπαίδευσης ..... 15
      5.2.5. Σχολιασμός Αποτελεσμάτων και Συσχέτιση με τη Δομή του Δικτύου 15
6. Συμπεράσματα ..... 16
7. Περιορισμοί και Παραδοχές της Ανάλυσης ..... 17

8. Προτάσεις για Μελλοντική Έρευνα ..... 17
9. Βιβλιογραφία & Αναφορές ..... 18

## Ευρετήριο Πινάκων

Πίνακας 1: Αποτελέσματα Grid Search στρατηγικών Node2Vec.....12
Πίνακας 2: Συγκριτική αξιολόγηση επιδόσεων μεταξύ των παραδοσιακών τοπολογικών δεικτών (Jaccard, Adamic-Adar) και της προτεινόμενης μεθόδου εκμάθησης αναπαραστάσεων (Node2Vec + Logistic Regression).....13
Πίνακας 3: Καμπύλες ROC για τη σύγκριση των μεθόδων πρόβλεψης συνδέσμων. .15

## Ευρετήριο Γραφημάτων

Γράφημα 1: Κατανομή βαθμών των κόμβων στο δίκτυο της Enron (Log-Log κλίμακα). .....4
Γράφημα 2: Κανονικοποιημένη κατανομή βαθμών P(k) σε log-log κλίμακα.....5

## Ευρετήριο Εικόνων

Εικόνα 1: Ego Network του κόμβου 5038 (υψηλότερο Degree Centrality). Κόκκινος κόμβος = central hub, μπλε κόμβοι = άμεσες επαφές (radius=1).....6
Εικόνα 2: Κοινοί γείτονες κόμβων 1628 ↔ 852. Κόκκινοι = ζεύγος κόμβων με κρυμμένη ακμή (test positive), Μπλε = 4 κοινοί γείτονες στον training graph (615, 516, 353, 1095). .....8
Εικόνα 3: Confusion Matrices για τις τρεις μεθόδους πρόβλεψης. TN (πάνω αριστερά) = σωστά αρνητικά, FP (πάνω δεξιά) = λανθασμένες προβλέψεις ακμής, FN (κάτω αριστερά) = χαμένες ακμές, TP (κάτω δεξιά) = σωστά εντοπισμένες ακμές. .....14
Εικόνα 4: Αποτελέσματα ελέγχου υπερεκπαίδευσης .....15

# 1. Εισαγωγή

## 1.1. Περιγραφή Προβλήματος

Το πρόβλημα της πρόβλεψης συνδέσμων (Link Prediction) αποτελεί ένα από τα πιο θεμελιώδη και ευρέως μελετημένα ζητήματα στο πεδίο της Θεωρίας Γράφων και της Ανάλυσης Δικτύων (Network Analysis). Το πρόβλημα αυτό αφορά την ικανότητα να εκτιμήσουμε την πιθανότητα δημιουργίας μιας μελλοντικής ακμής ή την ύπαρξη μιας ήδη παρούσας αλλά κρυφής ακμής μεταξύ δύο μη συνδεδεμένων κόμβων, βασιζόμενοι στην παρατηρούμενη τοπολογία του γράφου και τα χαρακτηριστικά των κόμβων του.

Η σημασία της πρόβλεψης συνδέσμων είναι τεράστια, καθώς αποτελεί τον πυρήνα πολλών σύγχρονων αλγοριθμικών συστημάτων στην καθημερινότητά μας. Χαρακτηριστικά παραδείγματα αποτελούν τα συστήματα συστάσεων (recommender systems) των κοινωνικών δικτύων, τα οποία προτείνουν νέους φίλους ή συνεργάτες (π.χ. «Άτομα που ίσως γνωρίζετε» σε Facebook και LinkedIn), αλλά και πλατφόρμες e-commerce που προτείνουν σχετικά προϊόντα (π.χ. Amazon). Παράλληλα, η ίδια λογική εφαρμόζεται με τεράστια επιτυχία στη βιοπληροφορική για την ανακάλυψη πιθανών αλληλεπιδράσεων μεταξύ φαρμάκων ή πρωτεϊνών, καθώς και στην ανάλυση εγκληματολογικών δικτύων για τον εντοπισμό αφανών διασυνδέσεων.

Στην παρούσα εργασία, η ανάλυση εστιάζει στην εφαρμογή της θεωρίας δικτύων σε ένα πραγματικό επιχειρηματικό περιβάλλον. Πιο συγκεκριμένα, για τους σκοπούς της μελέτης επιλέχθηκε το σύνολο δεδομένων Enron Email Network από το αποθετήριο του Stanford (SNAP). Το δίκτυο αυτό μοντελοποιεί την ανταλλαγή ηλεκτρονικών μηνυμάτων μεταξύ των στελεχών της ομώνυμης εταιρείας, αποτελώντας ένα κλασικό παράδειγμα για αναλύσεις «People Analytics» και κατανόησης της ροής της πληροφορίας μέσα σε έναν οργανισμό.

Στο πλαίσιο της αναφοράς, θα παρουσιαστεί αρχικά η δομική ανάλυση του γράφου της Enron μέσω της μελέτης της κατανομής βαθμού (degree distribution), των συνεκτικών συνιστωσών και των μέτρων κεντρικότητας (betweenness, closeness, eigenvector centrality). Στη συνέχεια, το πρόβλημα θα διαμορφωθεί ως έργο μηχανικής μάθησης, όπου θα υλοποιηθούν και θα συγκριθούν κλασικές ευρετικές μέθοδοι πρόβλεψης συνδέσμων (όπως οι Jaccard Coefficient και Adamic-Adar Index) με πιο προχωρημένες τεχνικές αναπαράστασης κόμβων όπως η μέθοδος ενσωμάτωσης Node2Vec. Τέλος, οι μέθοδοι θα αξιολογηθούν πειραματικά σε επίπεδο διαχωρισμού train/test μέσω μετρικών όπως η καμπύλη ROC (AUC) και η Ακρίβεια (Precision), ώστε να εξαχθούν συμπεράσματα για το ποιος αλγόριθμος μπορεί να προβλέψει με μεγαλύτερη επιτυχία τα κρυφά κανάλια επικοινωνίας στο εταιρικό αυτό δίκτυο.

# 2. Περιγραφή και Χαρακτηριστικά Δεδομένων

## 2.1. Επιλογή και Περιγραφή Δεδομένων

Όπως αναφέρθηκε στην προηγούμενη ενότητα επιλέχθηκε το σύνολο δεδομένων Enron Email Network, το οποίο αντλήθηκε από το αποθετήριο ανοιχτών δεδομένων

SNAP (Stanford Network Analysis Project). Το συγκεκριμένο dataset καλύπτει το σύνολο της ηλεκτρονικής επικοινωνίας (περίπου μισό εκατομμύριο emails) των στελεχών της εταιρείας Enron. Τα δεδομένα αυτά έγιναν αρχικά δημόσια διαθέσιμα από την Ομοσπονδιακή Ρυθμιστική Επιτροπή Ενέργειας των ΗΠΑ (Federal Energy Regulatory Commission) κατά τη διάρκεια της έρευνας για το οικονομικό σκάνδαλο της εταιρείας, ενώ η τελική μορφή του δικτύου δημοσιεύτηκε από τον William Cohen (Carnegie Mellon University).

**Κόμβοι (Nodes)**

Κάθε κόμβος του δικτύου αναπαριστά μια μοναδική διεύθυνση ηλεκτρονικού ταχυδρομείου. Στο δίκτυο περιλαμβάνονται και εξωτερικές διευθύνσεις (εκτός Enron), οι οποίες λειτουργούν σημεία προέλευσης ή τερματισμού πληροφορίας, καθώς παρατηρείται μόνο η αλληλεπίδρασή τους με τα στελέχη της Enron.

**Ακμές (Edges)**

Αν η διεύθυνση i έστειλε τουλάχιστον ένα email στη διεύθυνση j, δημιουργείται μια ακμή που ενώνει τους δύο κόμβους.

**Είδος του Γράφου**

Βάσει της μορφοποίησης του SNAP, το δίκτυο μοντελοποιείται ως μη κατευθυνόμενος (undirected) και μη ζυγισμένος (unweighted) γράφος. Αυτό σημαίνει ότι εξετάζουμε απλώς την ύπαρξη επικοινωνίας μεταξύ δύο ατόμων, ανεξάρτητα από τη συχνότητα (βάρος) ή το ποιος ξεκίνησε τη συζήτηση (κατεύθυνση). Ο συνολικός αριθμός κόμβων είναι 36.692 και ο συνολικός αριθμός ακμών 183.831.

## 3. Εξερευνητική Ανάλυση Δικτύου (Exploratory Data Analysis)

Στην παρούσα ενότητα αναλύεται η τοπολογία του εταιρικού δικτύου της Enron, προκειμένου να κατανοηθεί η δομή της επικοινωνίας μεταξύ των στελεχών πριν την εφαρμογή των αλγορίθμων πρόβλεψης συνδέσμων. Από την εξερευνητική ανάλυση (Exploratory Data Analysis) προκύπτουν σημαντικά συμπεράσματα για τον τρόπο με τον οποίο έρεε η πληροφορία στο εσωτερικό της εταιρείας.

### 3.1. Μακροσκοπική Δομή και Ταχύτητα Διάδοσης

Η ανάλυση ανέδειξε ότι το δίκτυο αποτελείται συνολικά από 1065 συνεκτικές συνιστώσες. Ωστόσο, παρατηρείται η ύπαρξη μιας απόλυτα κυρίαρχης δομής.

**Γιγαντιαία Συνιστώσα (Largest Connected Component)**

Η γιγαντιαία συνιστώσα περιέχει 33.696 κόμβους, καταλαμβάνοντας το 91.8% του δικτύου. Δεδομένου ότι το δίκτυο μελετάται ως μη κατευθυνόμενο (undirected), αυτό υποδεικνύει ότι η συντριπτική πλειοψηφία των υπαλλήλων ανήκει σε ένα ενιαίο, διασυνδεδεμένο σύστημα επικοινωνίας. Πρακτικά, μια πληροφορία που

εισάγεται στο δίκτυο μπορεί δυνητικά να φτάσει στο 92% της εταιρείας μέσω ενδιάμεσων επαφών. Το υπόλοιπο 8% αφορά κυρίως απομονωμένους κόμβους ή εξωτερικούς συνεργάτες.

**Διάμετρος Δικτύου (Diameter)**

Σύμφωνα με τα επίσημα στατιστικα του SNAP η μεγαλύτερη δυνατή συντομότερη διαδρομή (longest shortest path) μεταξύ δύο οποιωνδήποτε συνδεδεμένων κόμβων είναι 11. Δηλαδή, για να επικοινωνήσουν οι δύο πιο απομακρυσμένοι λογαριασμοί, ένα μήνυμα θα χρειαζόταν το πολύ 11 ενδιάμεσες προωθήσεις.

**Ενεργή Διάμετρος 90% (90-percentile Effective Diameter)**

Επιπλέον, σύμφωνα με τα στατιστικά του dataset, η ενεργή διάμετρος είναι 4.8 και αποτελεί ένα πιο αντιπροσωπευτικό μέτρο επειδή η μέγιστη διάμετρος μπορεί να επηρεαστεί από ακραίες περιπτώσεις (outliers). Στο 90% των περιπτώσεων, δύο οποιοιδήποτε υπάλληλοι απέχουν μεταξύ τους λιγότερο από 5 ενδιάμεσες επαφές. Το εύρημα αυτό επιβεβαιώνει το φαινόμενο του «μικρού κόσμου» (six degrees of separation), υποδεικνύοντας ότι η ροή της πληροφορίας είναι ταχύτατη και τα κορυφαία στελέχη είναι εύκολα προσβάσιμα.

### 3.2. Συσταδοποίηση και Συνεργασία

Η ανάλυση της τοπικής γειτονιάς των κόμβων αναδεικνύει τον τρόπο με τον οποίο σχηματίζονται οι ομάδες εργασίας.

**Συντελεστής Συσταδοποίησης (Clustering Coefficient)**

Ο μέσος συντελεστής του δικτύου ανέρχεται σε 0.4970 (ή 49.7%) σύμφωνα με τα επίσημα στατιστικά. Αξίζει να σημειωθεί ότι, εξαιτίας της πολυπλοκότητας του αλγορίθμου για την εύρεση όλων των πιθανών τριγώνων σε ένα δίκτυο 36.000 κόμβων, ο μέσος συντελεστής συσταδοποίησης υπολογίστηκε προσεγγιστικά και ανέρχεται σε 0.5042. Εφαρμόστηκε η μέθοδος τυχαίας δειγματοληψίας (approximation) με 5.000 επαναλήψεις, μια καθιερωμένη πρακτική στην ανάλυση μεγάλων γράφων που μειώνει δραστικά τον χρόνο εκτέλεσης διατηρώντας την ακρίβεια της μετρικής. Η τιμή αυτή είναι ιδιαίτερα υψηλή και αντανακλά την τυπική «κλαδική» δομή των επιχειρήσεων. Αν ο υπάλληλος Α επικοινωνεί με τον Β και τον Γ, υπάρχει 50% πιθανότητα οι Β και Γ να επικοινωνούν και μεταξύ τους. Το δίκτυο χαρακτηρίζεται από ισχυρές ομάδες, οι οποίες πρακτικά ταυτίζονται με τα διαφορετικά τμήματα της εταιρείας.

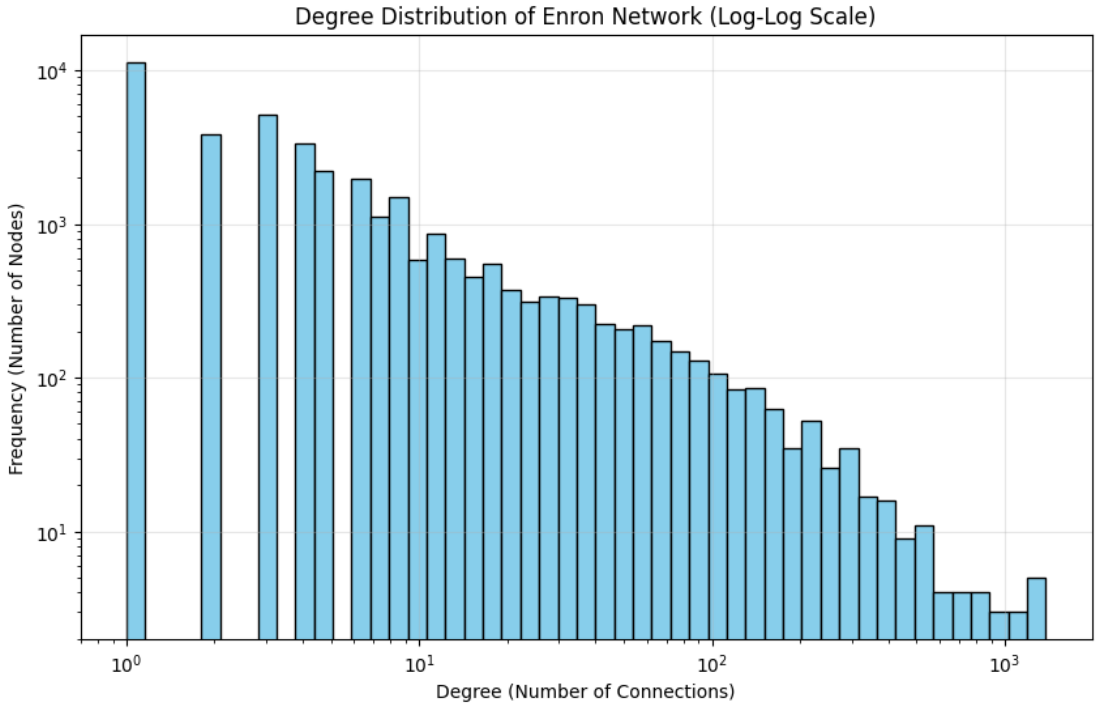
**Αριθμός Τριγώνων (Number of Triangles)**

Στην Enron καταγράφονται 727.044 κλειστά τρίγωνα (όπου τρεις κόμβοι επικοινωνούν όλοι μεταξύ τους). Το πλήθος αυτό υποδηλώνει τεράστια ομαδική συνεργασία και συνεδριάσεις σε μικρές ομάδες, αντί για μια απλή, κάθετη ιεραρχία.

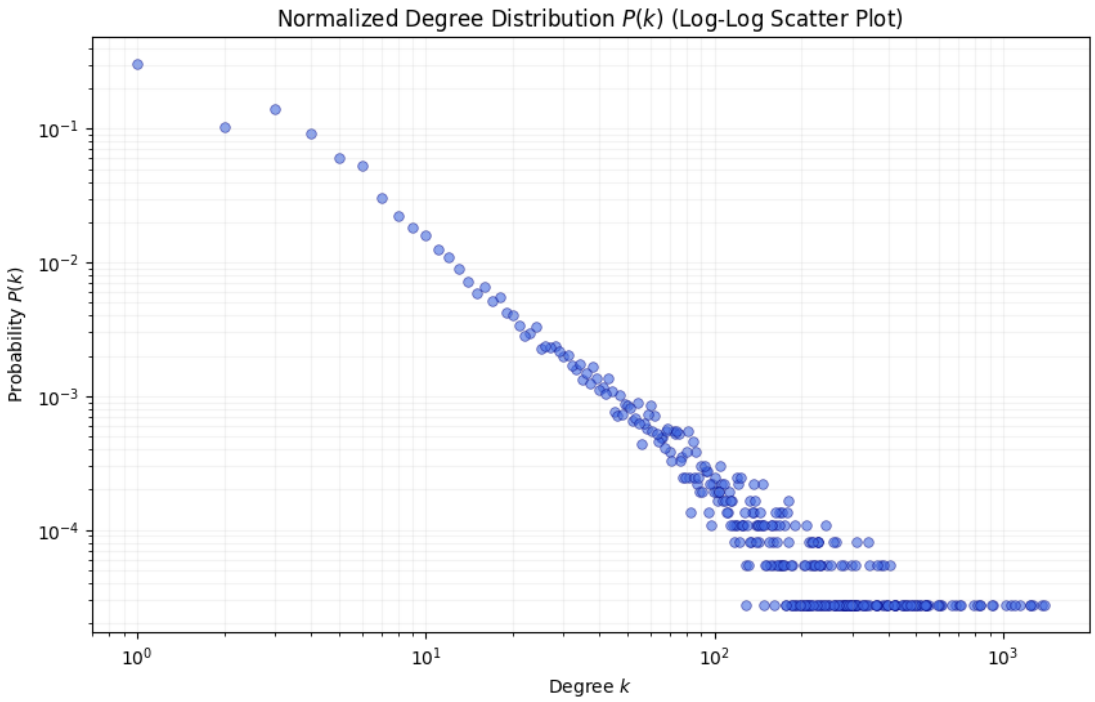
**Μεταβατικότητα (Transitivity)**

Το ποσοστό των κλειστών τριγώνων επί του συνόλου των πιθανών συνδέσεων υπολογίστηκε στο 0.0853 (8.53%). Παρατηρείται μια σημαντική απόκλιση από την τιμή 0.0301 (3%) που αναφέρεται στα metadata του αρχείου από το Stanford SNAP. Η διαφορά αυτή επεξηγείται από τη μεθοδολογία επεξεργασίας. Το αρχείο email-Enron.txt περιλαμβάνει 367.662 εγγραφές, καθώς το SNAP καταγράφει κάθε μη κατευθυνόμενη ακμή δύο φορές (μία ως "A προς B" και μία ως "B προς A", όπως μαρτυρά η επικεφαλίδα FromNodeId - ToNodeId). Στην παρούσα ανάλυση, ο γράφος μοντελοποιήθηκε ως Simple Graph (χρησιμοποιώντας τη δομή nx.Graph() της NetworkX), η οποία αναγνωρίζει και συγχωνεύει τα διπλότυπα ζεύγη σε μία μοναδική ακμή (183.831 μοναδικές συνδέσεις). Αυτή η εκκάθαρση των δεδομένων μείωσε τον παρονομαστή των πιθανών τριγώνων, αποδίδοντας μια πιο ακριβή εικόνα της κοινωνικής δομής της εταιρείας. Επιχειρηματικά, το 8.53% υποδηλώνει ότι ενώ η ιεραρχία παραμένει ισχυρή, ο ιστός των πραγματικών γνωριμιών είναι πολύ πιο σφιχτός από ό,τι θα άφηνε να εννοηθεί η απλή καταμέτρηση των emails.

## 3.3. Κατανομή Βαθμού (Degree Distribution)




*Γράφημα 1: Κατανομή βαθμών των κόμβων στο δίκτυο της Enron (Log-Log κλίμακα).*




*Γράφημα 2: Κανονικοποιημένη κατανομή βαθμών P(k) σε log-log κλίμακα.*

Όπως φαίνεται στο Διάγραμμα 1, η κατανομή βαθμού σε λογαριθμική κλίμακα (Log-Log) ακολουθεί σαφή κατανομή νόμου δύναμης. Αυτό σημαίνει ότι η συντριπτική πλειοψηφία των υπαλλήλων επικοινωνεί με έναν μικρό, περιορισμένο κύκλο ατόμων (τοπική επικοινωνία στο τμήμα τους). Αντίθετα, υπάρχει ένας πολύ μικρός αριθμός «κόμβων-κέντρων» (hubs), οι οποίοι διατηρούν εκατοντάδες συνδέσεις. Επιχειρηματικά, αυτά τα hubs πιθανότατα αντιπροσωπεύουν κεντρικές διευθύνσεις της εταιρείας (π.χ. HR, ανακοινώσεις CEO) ή αυτοματοποιημένα συστήματα ενημέρωσης.

### 3.4. Μέτρα Κεντρικότητας (Centrality Measures)

Για τον εντοπισμό των πιο κομβικών προσώπων στο δίκτυο της εταιρείας, υπολογίστηκαν τέσσερις διαφορετικές μετρικές κεντρικότητας. Οι 5 κορυφαίοι κόμβοι ανά κατηγορία, οι οποίοι εξυπηρετούν διαφορετικούς επιχειρηματικούς ρόλους, είναι:

**Degree Centrality - Κόμβοι: [5038, 273, 458, 140, 1028]**

Η μετρική αυτή αναδεικνύει τους λογαριασμούς με τις περισσότερες άμεσες επαφές στο δίκτυο. Επιχειρηματικά, οι κόμβοι αυτοί δεν έχουν απαραίτητα εξουσία, αλλά αποτελούν τους πιο «ενεργούς» κόμβους επικοινωνίας. Στο δίκτυο της Enron, συχνά αντιπροσωπεύουν κεντρικές γραμματείες, λογαριασμούς μαζικής ενημέρωσης (π.χ. HR announcements) ή υπαλλήλους με διευρυμένα, οριζόντια οργανωτικά καθήκοντα.

**Betweenness Centrality - Κόμβοι: [140, 5038, 566, 823, 273]**

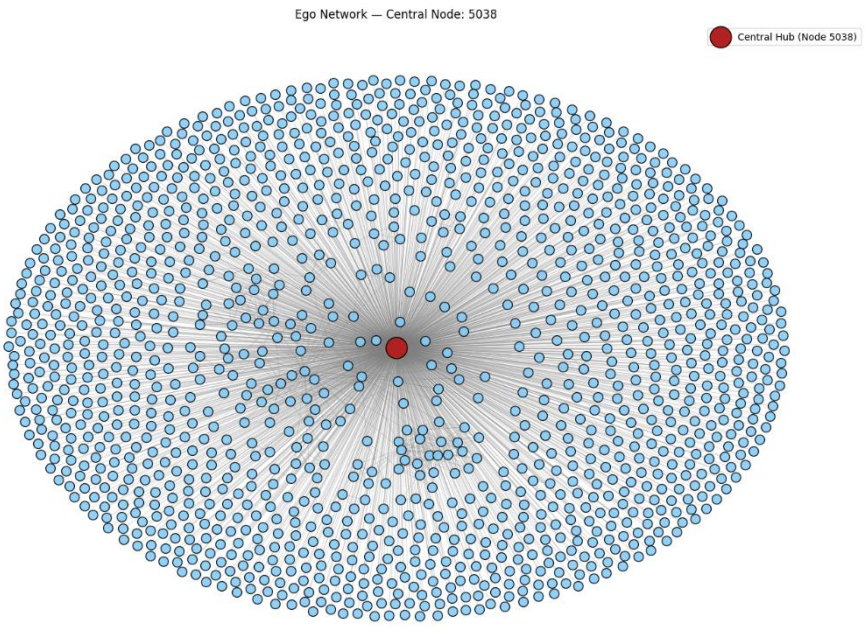
Τα άτομα αυτά λειτουργούν ως «γέφυρες» πληροφορίας. Δεν έχουν απαραίτητα τις περισσότερες επαφές, αλλά βρίσκονται στα συντομότερα μονοπάτια επικοινωνίας μεταξύ διαφορετικών τμημάτων (π.χ. middle managers ή γραμματείς στελεχών). Αν αφαιρεθούν, η ροή πληροφορίας στην εταιρεία θα διακοπεί. Το Betweenness Centrality υπολογίστηκε προσεγγιστικά με δειγματοληψία k=100 κόμβων (seed=42 για αναπαραγωγιμότητα), λόγω του υψηλού υπολογιστικού κόστους $O(N^3)$ για τον ακριβή υπολογισμό σε δίκτυο 36.692 κόμβων.

**Eigenvector Centrality- Κόμβοι: [136, 195, 76, 370, 1028]**

Οι κόμβοι αυτοί αντλούν την επιρροή τους επειδή συνδέονται με άλλους εξίσου σημαντικούς κόμβους. Επιχειρηματικά, πρόκειται πιθανότατα για το Διοικητικό Συμβούλιο και τα κορυφαία στελέχη, τα οποία συζητούν στενά μεταξύ τους και λαμβάνουν τις αποφάσεις.

**Closeness Centrality - Κόμβοι [136, 76, 46, 140, 370]**

Τα άτομα αυτά χρειάζονται τα λιγότερα ενδιάμεσα βήματα για να φτάσουν σε όλους τους άλλους υπαλλήλους. Λόγω της τοπολογικής τους θέσης, είναι ιδανικά για να διαδώσουν (ή να πληροφορηθούν) μια είδηση στον ελάχιστο δυνατό χρόνο σε όλη την κλίμακα της εταιρείας.




*Εικόνα 1: Ego Network του κόμβου 5038 (υψηλότερο Degree Centrality). Κόκκινος κόμβος = central hub, μπλε κόμβοι = άμεσες επαφές (radius=1)*

Η παραπάνω εικόνα απεικονίζει το Ego Network του κόμβου 5038, του κόμβου με το υψηλότερο Degree Centrality στο δίκτυο της Enron. Κάθε μπλε κόμβος αντιπροσωπεύει έναν άμεσο επικοινωνιακό εταίρο. Το γράφημα αναδεικνύει

χαρακτηριστικά την ακτινωτή δομή ενός hub, ο κεντρικός κόμβος συνδέεται άμεσα με εκατοντάδες επαφές. Η απουσία πυκνών διασυνδέσεων μεταξύ των περιφερειακών κόμβων υποδηλώνει ότι ο κόμβος 5038 λειτουργεί ως κεντρικός διαμεσολαβητής επικοινωνίας.

## 4. Μεθοδολογία Πρόβλεψης Συνδέσμων

Η πρόβλεψη συνδέσμων (Link Prediction) αντιμετωπίζεται ως ένα πρόβλημα Δυαδικής Ταξινόμησης. Στόχος είναι να εκπαιδευτεί ένας αλγόριθμος που, δεδομένου ενός ζεύγους κόμβων (u, v), θα μπορεί να προβλέψει αν η τιμή είναι 1 (θα υπάρξει σύνδεση) ή 0 (δεν θα υπάρξει σύνδεση).

### 4.1. Δημιουργία Θετικών Δειγμάτων (Label 1)

Τα θετικά δείγματα είναι ακμές που γνωρίζουμε ήδη ότι υπάρχουν στο dataset της Enron. Επιλέγουμε τυχαία ένα ποσοστό (π.χ. 10%) από τις υπάρχουσες ακμές και τις «κρύβουμε» από τον αλγόριθμο. Το μοντέλο θα προσπαθήσει να τις ανακαλύψει ξανά, βασιζόμενο μόνο στον εναπομείναντα γράφο. Αν ο αλγόριθμος τους δώσει υψηλό σκορ, σημαίνει ότι λειτουργεί σωστά.

### 4.2. Δημιουργία Αρνητικών Δειγμάτων (Label 0)

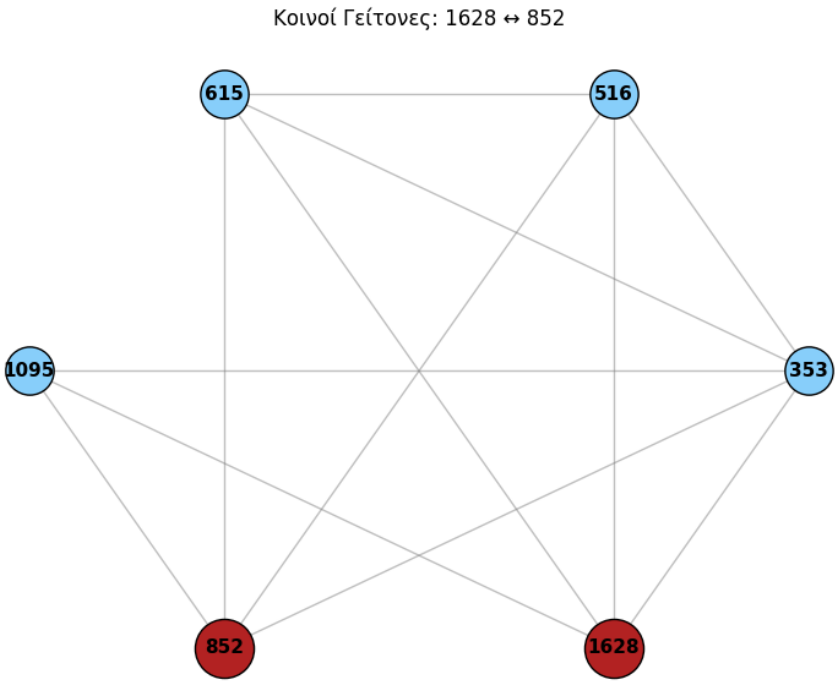
Ένα μοντέλο δεν μπορεί να μάθει αν βλέπει μόνο επιτυχίες πρέπει να δει και αποτυχίες. Τα αρνητικά δείγματα είναι ζεύγη υπαλλήλων (u, v) που δεν αντάλλαξαν ποτέ email. Επιλέγουμε τυχαία ζεύγη κόμβων από το δίκτυο, ελέγχοντας ότι δεν υπάρχει ακμή μεταξύ τους στο αρχικό dataset.

Δημιουργούμε ακριβώς τον ίδιο αριθμό αρνητικών δειγμάτων με τα θετικά. Δημιουργείται ένα ισορροπημένο σύνολο δεδομένων και αποτρέπει το μοντέλο από το να μαντεύει πάντα ότι θα υπάρξει σύνδεση (bias).

### 4.3. Ο Γράφος Εκπαίδευσης (Training Graph)

Αφού αφαιρέσουμε τα θετικά δείγματα (το 10% των ακμών), ο γράφος που απομένει ονομάζεται Training Graph. Όλες οι μετρικές υπολογίζονται αποκλειστικά πάνω σε αυτόν τον μειωμένο γράφο.

Το παρακάτω σχήμα απεικονίζει ένα χαρακτηριστικό παράδειγμα κοινών γειτόνων για ένα ζεύγος κόμβων του δικτύου. Οι κόμβοι 1628 και 852 μοιράζονται 4 κοινούς γείτονες στον training graph, η πραγματική τους σύνδεση έχει κρυφτεί και αποτελεί θετικό δείγμα του test set που καλείται να προβλέψει ο αλγόριθμος.




*Εικόνα 2: Κοινοί γείτονες κόμβων 1628 ↔ 852. Κόκκινοι = ζεύγος κόμβων με κρυμμένη ακμή (test positive), Μπλε = 4 κοινοί γείτονες στον training graph (615, 516, 353, 1095).*

## 4.4. Μέθοδοι Πρόβλεψης Συνδέσμων (Link Prediction Methods)

### 4.4.1. Τοπολογικές Μέθοδοι Βασισμένες στη Γειτονιά (Neighborhood-based Metrics)

Σε αυτή την κατηγορία εξετάζονται οι παραδοσιακοί αλγόριθμοι που βασίζονται αποκλειστικά στη δομή των κοινών γειτόνων στον γράφο.

#### *4.4.1.1. Συντελεστής Jaccard (Jaccard Coefficient)*

Ο συντελεστής Jaccard αποτελεί μια μετρική ομοιότητας που βασίζεται στην επικάλυψη των γειτονικών κόμβων. Υπολογίζεται ως ο λόγος του αριθμού των κοινών γειτόνων μεταξύ δύο υπαλλήλων προς τον συνολικό αριθμό των μοναδικών επαφών τους:

$$J(u,v) = \frac{|\Gamma(u) \cap \Gamma(v)|}{|\Gamma(u) \cup \Gamma(v)|}$$

όπου:

- u, v: Το ζεύγος των υπαλλήλων (κόμβων) για τους οποίους εξετάζεται η πιθανότητα σύνδεσης.
- Γ(u), Γ(v): Τα σύνολα των γειτόνων (άμεσων επαφών) των κόμβων u και v αντίστοιχα.

Στο πλαίσιο του δικτύου της Enron, ο αλγόριθμος υποθέτει ότι όσο μεγαλύτερο ποσοστό κοινών επαφών μοιράζονται δύο άτομα, τόσο πιθανότερο είναι να ανήκουν στην ίδια οργανωτική δομή ή ομάδα εργασίας, αυξάνοντας έτσι την πιθανότητα

μελλοντικής επικοινωνίας. Πρόκειται για μια δημοκρατική μετρική, καθώς αντιμετωπίζει όλους τους κοινούς γείτονες ως ισοδύναμους, ανεξάρτητα από τον συνολικό βαθμό κεντρικότητάς τους.

#### *4.4.1.2. Δείκτης Adamic-Adar (Adamic-Adar Index)*

Ο δείκτης Adamic-Adar εισάγει έναν συντελεστή βαρύτητας για κάθε κοινό γείτονα. Αντί για απλή καταμέτρηση, ο αλγόριθμος αποδίδει μεγαλύτερη αξία σε κοινούς γείτονες που έχουν περιορισμένο αριθμό συνολικών συνδέσεων, χρησιμοποιώντας τον αντίστροφο λογάριθμο του βαθμού τους.

$$A(u,v) = \sum_{w \in \Gamma(u) \cap \Gamma(v)} \frac{1}{log(|\Gamma(w)|)}$$

όπου:

- u, v: Αντιπροσωπεύουν το ζεύγος των υπαλλήλων (κόμβων) για τους οποίους προσπαθούμε να προβλέψουμε αν υπάρχει ή θα υπάρξει σύνδεση.
- w: Ο εκάστοτε κοινός γείτονας που ανήκει στην τομή των συνόλων Γ(u) και Γ(v).
- Γ(w): Ο βαθμός (degree) του κοινού γείτονα w, δηλαδή ο συνολικός αριθμός των επαφών του.

Η λογική πίσω από αυτή τη μετρική είναι ότι οι σπάνιες κοινές επαφές υποδηλώνουν ισχυρότερη και πιο εξειδικευμένη σχέση μεταξύ δύο κόμβων. Στο εταιρικό δίκτυο της Enron, αυτό επιτρέπει στον αλγόριθμο να αγνοεί τον θόρυβο που προκαλούν οι κεντρικοί κόμβοι (hubs), όπως το τμήμα HR ή οι αυτοματοποιημένες ενημερώσεις, και να εστιάζει σε μικρότερες, συνεκτικές ομάδες όπου η πληροφορία ρέει πιο στοχευμένα.

Η χρήση του Katz Index δεν επελέγει λόγω υπολογιστικού κόστους $O(N^3)$ για N=36.692 κόμβους. Οι Jaccard και Adamic-Adar επιλέχθηκαν καθώς βασίζονται σε τοπικές γειτονιές, κλιμακώνονται άψογα και ταιριάζουν με την έντονα τοπική δομή του δικτύου Enron (clustering coefficient = 0.497).

### 4.4.2. Προχωρημένες Μέθοδοι- Εκμάθηση Αναπαραστάσεων (Representation Learning)

Σε αυτή την ενότητα υλοποιείται μια πιο εξελιγμένη προσέγγιση, όπου ο γράφος μετατρέπεται σε αριθμητικά διανύσματα για την εκπαίδευση μοντέλων μηχανικής μάθησης.

#### *4.4.2.1. Embeddings με τη χρήση του αλγορίθμου Node2Vec*

Η μέθοδος Node2Vec αποτελεί μια σύγχρονη προσέγγιση που βασίζεται στην εκμάθηση αναπαραστάσεων (embeddings). Αντί να βασίζεται σε στατικές μετρικές, ο αλγόριθμος μετατρέπει κάθε κόμβο του δικτύου σε ένα διάνυσμα (vector) χαμηλής διάστασης σε έναν ευκλείδειο χώρο, διατηρώντας όμως τις τοπολογικές ιδιότητες του γράφου.
Η διαδικασία βασίζεται σε μεροληπτικούς τυχαίους περιπάτους (biased random walks). Ο αλγόριθμος «περπατά» στο δίκτυο της Enron ξεκινώντας από κάθε

υπάλληλο και εξερευνά τη γειτονιά του, χρησιμοποιώντας δύο παραμέτρους (p και q) που ελέγχουν αν η εξερεύνηση θα είναι τοπική (BFS-like) ή σε βάθος (DFS-like). Οι διαδρομές αυτές χρησιμοποιούνται στη συνέχεια για την εκπαίδευση ενός μοντέλου (Skip-gram), παρόμοιου με το Word2Vec που χρησιμοποιείται στην επεξεργασία φυσικής γλώσσας.

Σε αντίθεση με τον Jaccard ή τον Adamic-Adar, το Node2Vec επιτρέπει στο μοντέλο να αντιληφθεί βαθύτερες δομικές ομοιότητες που δεν περιορίζονται μόνο στους κοινούς φίλους.

- **Edge Features:** Για κάθε ζεύγος υπαλλήλων (u, v), συνδυάζουμε τα αντίστοιχα διανύσματά τους (χρησιμοποιώντας το γινόμενο Hadamard - στοιχείο προς στοιχείο πολλαπλασιασμό) για να δημιουργήσουμε ένα νέο διάνυσμα που αντιπροσωπεύει την πιθανή ακμή.
- **Ταξινόμηση:** Αυτά τα διανύσματα τροφοδοτούνται σε έναν αλγόριθμο μηχανικής μάθησης (όπως η Λογιστική Παλινδρόμηση - Logistic Regression στην περίπτωση της παρούσας εργασίας), ο οποίος μαθαίνει να διακρίνει αν τα χαρακτηριστικά του διανύσματος υποδηλώνουν πραγματική επικοινωνία ή τυχαία γειτνίαση.

Στο δίκτυο της Enron, το Node2Vec είναι ιδιαίτερα ισχυρό γιατί μπορεί να εντοπίσει υπαλλήλους που έχουν παρόμοιους ρόλους στην εταιρεία (π.χ. δύο άτομα σε διαφορετικά τμήματα που όμως λειτουργούν και οι δύο ως «γέφυρες»), ακόμα και αν δεν μοιράζονται άμεσα κοινούς γείτονες, προσφέροντας έτσι μια πιο σφαιρική ανάλυση της οργανωτικής δομής.

#### *4.4.2.2. Περιγραφή Μεθοδολογίας Node2Vec και Ταξινόμησης*

Η διαδικασία πρόβλεψης συνδέσμων μέσω της μεθόδου εκμάθησης αναπαραστάσεων πραγματοποιήθηκε σε 2 στάδια.

**Στάδιο 1 - (Εκμάθηση Αναπαραστάσεων & Feature Engineering)**

Αρχικά, εφαρμόστηκε ο αλγόριθμος Node2Vec στον γράφο εκπαίδευσης όπου μέσω μεροληπτικών τυχαίων περιπάτων (biased random walks) και της αρχιτεκτονικής Skip-gram (Word2Vec) οι κόμβοι του δικτύου μετατράπηκαν σε διανύσματα χαμηλής διάστασης, ενσωματώνοντας τοπολογικές πληροφορίες της γειτονιάς τους. Συγκεκριμένα, το μοντέλο εκπαιδεύτηκε να προβλέπει το δίκτυο επαφών κάθε κόμβου βάσει των τυχαίων περιπάτων, αποδίδοντας έτσι παρόμοια διανυσματική αναπαράσταση σε υπαλλήλους με κοινά μοτίβα επικοινωνίας. Στη συνέχεια, πραγματοποιήθηκε η μηχανική χαρακτηριστικών (feature engineering) για τις ακμές, όπου τα διανύσματα των ζευγών των κόμβων συνδυάστηκαν μέσω του γινομένου Hadamard (στοιχείο προς στοιχείο πολλαπλασιασμός). Σε αυτό το σημείο, παρήχθη ένα ισορροπημένο σύνολο δεδομένων με θετικά και αρνητικά δείγματα, και οι τελικοί πίνακες χαρακτηριστικών (X_train, X_test) καθώς και οι ετικέτες τους (y_train, y_test) αποθηκεύτηκαν απευθείας στον δίσκο σε μορφή αρχείων NumPy (.npy).

**Στάδιο 2 - Επιβλεπόμενη Ταξινόμηση (Supervised Classification)**

Στο δεύτερο στάδιο της μεθοδολογίας, ο στόχος ήταν η αξιοποίηση των εξαχθέντων διανυσμάτων για την τελική πρόβλεψη των συνδέσμων του δικτύου. Τα παραγόμενα node embeddings τροφοδοτήθηκαν στον ταξινομητή της Λογιστικής Παλινδρόμησης, ο οποίος εκπαιδεύτηκε για να διακρίνει τις πραγματικές από τις ανύπαρκτες επικοινωνίες. Επιλέχθηκε η διατήρηση των προεπιλεγμένων ρυθμίσεων του αλγορίθμου, καθώς ανταποκρίνονται στη φύση των πυκνών διανυσμάτων (dense vectors) που παρήγαγε το Node2Vec.

Πιο συγκεκριμένα, η προεπιλεγμένη κανονικοποίηση L2 (Ridge) εξασφάλισε ότι η πληροφορία κατανέμεται ομαλά και στις 128 διαστάσεις των διανυσμάτων, προστατεύοντας το μοντέλο από την υπερεκπαίδευση χωρίς να μηδενίζει χρήσιμα χαρακτηριστικά. Παράλληλα, οι προκαθορισμένες ρυθμίσεις για τον βελτιστοποιητή (lbfgs) και το όριο επαναλήψεων (max_iter=1000) αποδείχθηκαν επαρκείς για την ταχεία και ομαλή σύγκλιση του μοντέλου. Τέλος, δεν απαιτήθηκε αναπροσαρμογή στα βάρη των κλάσεων (class weights), καθώς η απόλυτη ισορροπία μεταξύ πραγματικών και ψεύτικων ακμών είχε ήδη διασφαλιστεί κατά το προηγούμενο στάδιο της αρνητικής δειγματοληψίας (negative sampling).

**Μεθοδολογία Διαχωρισμού και Αξιολόγησης (Hold-out Method)**

Όσον αφορά τη μεθοδολογία επικύρωσης του μοντέλου, εφαρμόστηκε η μέθοδος Hold-out (Train/Test split), όπου το 90% των πραγματικών ακμών χρησιμοποιήθηκε για την εκπαίδευση και το κρυφό 10% κρατήθηκε για την τελική αξιολόγηση. Η τελική αξιολόγηση του Hold-out μοντέλου πραγματοποιήθηκε στο ανεξάρτητο σύνολο ελέγχου (test set). Για μια σφαιρική και αντικειμενική εικόνα της ποιότητας του ταξινομητή, πέρα από τη συνολική μετρική AUC, υπολογίστηκαν και μετρικές που αξιολογούν εξειδικευμένα την ικανότητα του μοντέλου να εντοπίζει σωστά τις θετικές κλάσεις (πραγματικές ακμές), δηλαδή η Ακρίβεια (Precision), η Ανάκληση (Recall) και ο αρμονικός μέσος τους, το F1-Score.

### 4.5. Εργαλεία και Περιβάλλον Υλοποίησης

Η υλοποίηση της παρούσας εργασίας πραγματοποιήθηκε σε περιβάλλον Python. Για την επεξεργασία του γράφου και την εξαγωγή των τοπολογικών χαρακτηριστικών (Εξερευνητική Ανάλυση, Jaccard, Adamic-Adar) χρησιμοποιήθηκε η βιβλιοθήκη NetworkX. Λόγω του μεγάλου όγκου των δεδομένων, για την παραγωγή των μεροληπτικών τυχαίων περιπάτων (random walks) του Node2Vec επιλέχθηκε η βελτιστοποιημένη βιβλιοθήκη PecanPy, η οποία προσφέρει ταχύτερη εκτέλεση μέσω παράλληλης επεξεργασίας. Τα διανύσματα των κόμβων (embeddings) εκπαιδεύτηκαν μέσω της κλάσης Word2Vec της βιβλιοθήκης Gensim. Τέλος, η ταξινόμηση μέσω Λογιστικής Παλινδρόμησης (Logistic Regression) και ο υπολογισμός των μετρικών αξιολόγησης (AUC, Precision, Recall, F1-score) υλοποιήθηκαν με τη βιβλιοθήκη Scikit-learn, ενώ οι οπτικοποιήσεις παρήχθησαν μέσω των Matplotlib και Seaborn.

## 5. Πειραματική Αξιολόγηση

### 5.1. Μετρικές Αξιολόγησης

Για την εκτίμηση της ποιότητας των προβλέψεων, χρησιμοποιήθηκαν οι παρακάτω μετρικές:

1. **AUC (Area Under the ROC Curve):** Αντιπροσωπεύει την πιθανότητα το μοντέλο να κατατάξει μια τυχαία επιλεγμένη πραγματική ακμή (positive) υψηλότερα από μια τυχαία ανύπαρκτη (negative). Τιμή 0.5 υποδηλώνει τυχαία πρόβλεψη, ενώ τιμή 1.0 τέλεια ακρίβεια.
2. **Ακρίβεια (Precision):** Μετρά το ποσοστό των προβλεπόμενων συνδέσμων που είναι όντως πραγματικοί. Υπολογίζεται ως ο λόγος των Αληθώς Θετικών (TP) προς το σύνολο των Θετικών Προβλέψεων:

$$Precision = \frac{TP}{TP + FP}$$

(όπου FP: Ψευδώς Θετικά, δηλαδή ανύπαρκτοι σύνδεσμοι που προβλέφθηκαν λανθασμένα ως πραγματικοί).

3. **Ανάκληση (Recall):** Μετρά το ποσοστό των πραγματικών συνδέσμων που εντοπίστηκαν επιτυχώς από το μοντέλο.

$$Recall = \frac{TP}{TP + FN}$$

(όπου FN: Ψευδώς Αρνητικά, δηλαδή πραγματικοί σύνδεσμοι που διέφυγαν από το μοντέλο).

4. **F-measure (F1-score):** Ο αρμονικός μέσος μεταξύ Precision και Recall. Είναι ιδιαίτερα χρήσιμος στο Link Prediction καθώς αξιολογεί την απόδοση αγνοώντας τα πολυάριθμα Αληθώς Αρνητικά (TN) του αραιού γράφου, παρέχοντας μια ισορροπημένη εικόνα.

$$\mathrm{F1} = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

## 5.2. Ανάλυση Πειραμάτων

### 5.2.1. Υπερπαραμέτροι Node2Vec

Για την εκπαίδευση του μοντέλου, επιλέχθηκε η εκτέλεση 40 τυχαίων περιπάτων ανά κόμβο με μήκος 80 βήματα. Αυτή η εκτενής εξερεύνηση του δικτύου μέσω του PecanPy εξασφάλισε ότι δεν θα χαθεί καμία σημαντική πληροφορία για τις επαφές των υπαλλήλων, κάνοντας τα αποτελέσματά πιο αξιόπιστα. Επίσης, καθορίστηκε ότι το μαθηματικό «προφίλ» κάθε υπαλλήλου θα αποτελείται από 128 διαστάσεις (αριθμούς). Αυτή η επιλογή έδωσε στο νευρωνικό δίκτυο αρκετή ευελιξία ώστε να κατανοήσει την πολυπλοκότητα του δικτύου της Enron και να αποτυπώσει ακόμα και τις πιο έμμεσες σχέσεις μεταξύ των τμημάτων.Έχοντας σταθεροποιήσει τη χωρητικότητα αναπαράστασης του μοντέλου (καθώς και τις βασικές παραμέτρους του Word2Vec: Window Size = 10, Epochs = 5), η προσοχή στράφηκε στη στρατηγική περιήγησης στον γράφο, η οποία καθορίζεται από τις παραμέτρους επιστροφής (p) και μετακίνησης (q). Κατά τη διάρκεια των δοκιμών, εξετάστηκαν διαφορετικές στρατηγικές τυχαίων περιπάτων (Random Walks) με μεταβολή των παραμέτρων p και q. Η επιλογή των συγκεκριμένων παραμέτρων (40 περίπατοι, μήκος 80, παράθυρο 10, 5 εποχές) βασίστηκε στις βέλτιστες πρακτικές της σχετικής βιβλιογραφίας. Ο συνδυασμός αυτός επιλέχθηκε διότι προσφέρει τη «χρυσή τομή» μεταξύ της υπολογιστικής πολυπλοκότητας (χρόνος εκπαίδευσης και κατανάλωση μνήμης) και της επαρκούς αποτύπωσης της δομής του δικτύου. Όσον αφορά τις παραμέτρους p και q, πραγματοποιήθηκε στοχευμένη δοκιμή ακραίων τιμών (edge cases). Στόχος ήταν να αξιολογηθούν συγκεκριμένες δομικές υποθέσεις: η τάση του δικτύου προς την τοπική ομαδοποίηση (αναπαράσταση BFS), η ύπαρξη μονοπατιών επικοινωνίας μεγάλου μήκους (αναπαράσταση DFS), καθώς και η αμερόληπτη εξερεύνηση (DeepWalk). Οι στρατηγικές που αξιολογήθηκαν και τα αντίστοιχα αποτελέσματά τους σε επίπεδο AUC Score συνοψίζονται στον παρακάτω πίνακα:

| Στρατηγική | Παράμετροι (p, q) | AUC Score |
|---|---|---|
| **High Exploration** | **p=0.1, q=0.1** | **0.9273** |
| **BFS (Local)** | p=0.5, q=2.0 | 0.9205 |
| **DFS (Global)** | p=1.0, q=0.5 | 0.9193 |
| **DeepWalk** | p=1.0, q=1.0 | 0.9192 |

*Πίνακας 1: Αποτελέσματα Grid Search στρατηγικών Node2Vec.*

Όπως προκύπτει από τα δεδομένα, η στρατηγική HighExploration (p=0.1, q=0.1) σημείωσε την υψηλότερη απόδοση (AUC = 0.9273). Η στατιστική σημαντικότητα της

διαφοράς έναντι της BFS επιβεβαιώθηκε μέσω του DeLong's test ($Z = 5.82$, $p < 0.001$), αποκλείοντας την τυχαιότητα. Το εύρημα αυτό υποδηλώνει ότι το δίκτυο της Enron δεν χαρακτηρίζεται αποκλειστικά από τοπικές ομάδες εργασίας, αλλά και από ευρύτερες δομικές ιδιότητες που η μικτή εξερεύνηση (χαμηλά p και q) αποτυπώνει αποτελεσματικότερα. Αξίζει να σημειωθεί ότι η πρακτική διαφορά μεταξύ των στρατηγικών παραμένει μικρή (0.67%), καθώς όλες κυμαίνονται στο εύρος 0.919-0.927.

Παράλληλα, οι επιλεγμένες υπερπαράμετροι (128 διαστάσεις, 40 περίπατοι, μήκος 80) βασίστηκαν στις βέλτιστες πρακτικές της βιβλιογραφίας και αποδείχθηκαν επαρκείς για το συγκεκριμένο δίκτυο. Η συστηματική βελτιστοποίηση αυτών των παραμέτρων μέσω εκτενέστερου grid search αφήνεται ως κατεύθυνση μελλοντικής έρευνας.

### 5.2.2. Συγκριτική Αξιολόγηση Μοντέλων

Τα αποτελέσματα της πειραματικής αξιολόγησης στο ανεξάρτητο σύνολο ελέγχου (test set) συνοψίζονται στον παρακάτω πίνακα:

| Μέθοδος | AUC | Precision | Recall | F1-Score |
|---|---|---|---|---|
| **Adamic-Adar Index** | **0.9546** | **0.9814** | **0.9112** | **0.9450** |
| **Jaccard Coefficient** | 0.9488 | 0.9793 | 0.9121 | 0.9445 |
| **Node2Vec + Logistic Regression** | 0.9273 | 0.8553 | 0.8403 | 0.8478 |

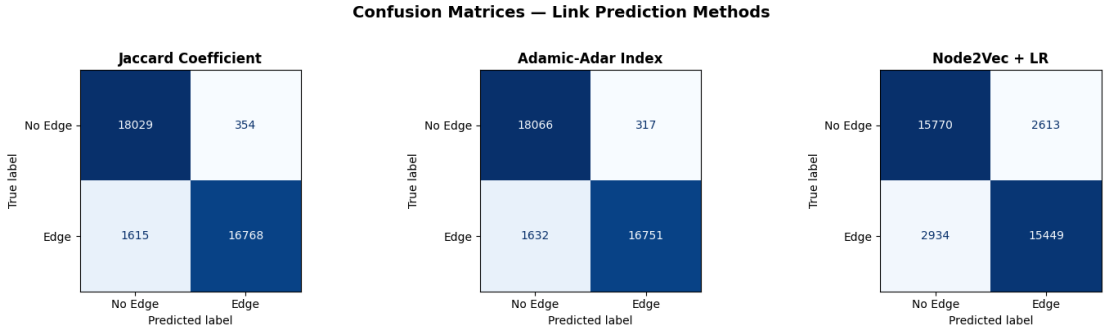
*Πίνακας 2: Συγκριτική αξιολόγηση επιδόσεων μεταξύ των παραδοσιακών τοπολογικών δεικτών (Jaccard, Adamic-Adar) και της προτεινόμενης μεθόδου εκμάθησης αναπαραστάσεων (Node2Vec + Logistic Regression).*

Από την ανάλυση των αποτελεσμάτων του παραπάνω πίνακα, καθίσταται σαφές ότι όλες οι μέθοδοι πέτυχαν υψηλή διαχωριστική ικανότητα, με τη μετρική AUC να ξεπερνά το 0.92 σε κάθε περίπτωση. Ωστόσο, παρατηρείται μια ξεκάθαρη υπεροχή των παραδοσιακών τοπολογικών μετρικών (Adamic-Adar και Jaccard) έναντι της μεθόδου εκμάθησης αναπαραστάσεων (Node2Vec + Logistic Regression).

Πιο συγκεκριμένα, ο δείκτης Adamic-Adar σημείωσε την κορυφαία συνολική απόδοση (AUC: 0.9546, F1-Score: 0.9450). Η επιτυχία αυτή οφείλεται στην ικανότητα του αλγορίθμου όχι απλώς να μετρά κοινούς γείτονες, αλλά να «τιμωρεί» τους κόμβους-κέντρα (hubs), όπως π.χ. κεντρικές διευθύνσεις μαζικών ενημερώσεων. Αυτό σημαίνει ότι έδωσε μεγαλύτερη βαρύτητα σε στενές, άμεσες συνεργασίες, επιτυγχάνοντας εντυπωσιακή Ακρίβεια (Precision: 0.9814). Ακολούθησε ο Jaccard Coefficient, επιβεβαιώνοντας ότι η αρχή της «κλειστότητας τριγώνων» (κοινοί συνάδελφοι) αποτελεί τον ισχυρότερο προγνωστικό παράγοντα στο δίκτυο της Enron. Στον αντίποδα, η προσέγγιση του Node2Vec, παρότι κατέγραψε υψηλό επίπεδο στο AUC (0.9273) και αξιόλογο Precision (0.8553), υστέρησε στο Recall (0.8403). Το χαμηλότερο αυτό ποσοστό Ανάκλησης υποδηλώνει ότι το μοντέλο αδυνατούσε να εντοπίσει περίπου το 16% των πραγματικών επικοινωνιών. Αυτό είναι ένα αναμενόμενο φαινόμενο, καθώς οι τυχαίοι περίπατοι τείνουν να χάνουν πληροφορία σε πιο αραιά ή απομονωμένα τμήματα του γράφου, ενώ οι τοπολογικές μετρικές εντοπίζουν απευθείας και με ακρίβεια τις τοπικές συνδέσεις.

Συμπερασματικά, για το συγκεκριμένο εταιρικό δίκτυο, οι απλοί κανόνες τοπικής γειτονίας αποδείχθηκαν καταλληλότεροι και πιο εύρωστοι από την πολυπλοκότητα των πυκνών διανυσματικών αναπαραστάσεων.

Για μια πιο αναλυτική εικόνα των σφαλμάτων κάθε μεθόδου, παρουσιάζονται οι Confusion Matrices στο παρακάτω σχήμα.



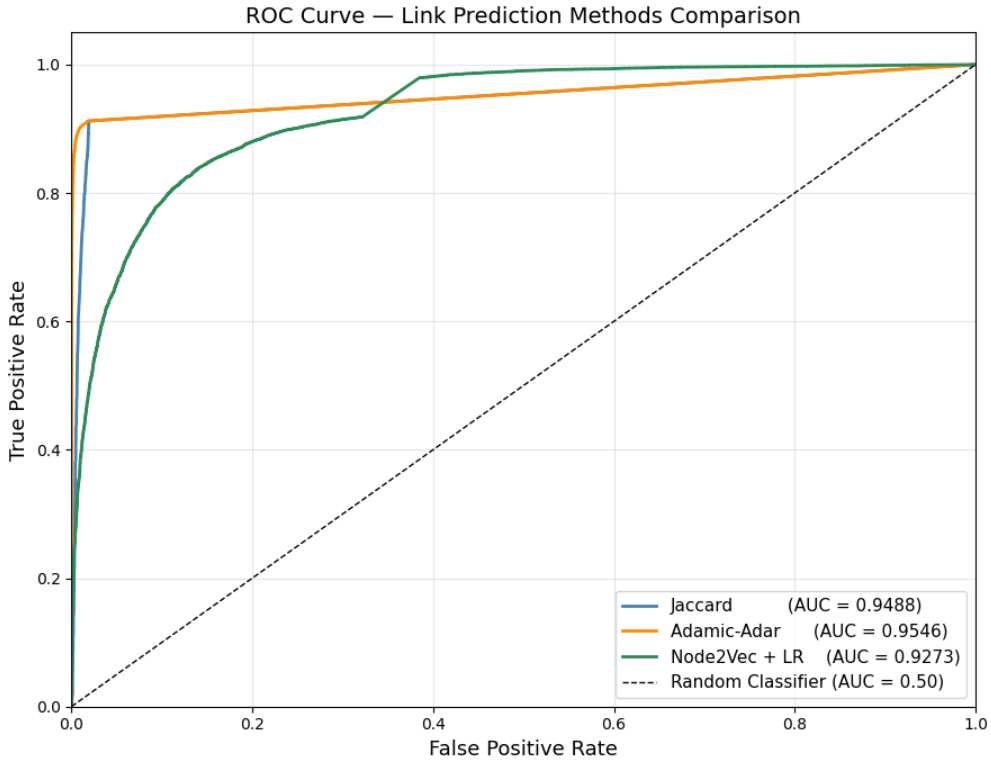

*Εικόνα 3: Confusion Matrices για τις τρεις μεθόδους πρόβλεψης. TN (πάνω αριστερά) = σωστά αρνητικά, FP (πάνω δεξιά) = λανθασμένες προβλέψεις ακμής, FN (κάτω αριστερά) = χαμένες ακμές, TP (κάτω δεξιά) = σωστά εντοπισμένες ακμές.*

Jaccard και Adamic-Adar εμφανίζουν ελάχιστα False Positives (354 και 317 αντίστοιχα), όταν προβλέπουν ακμή, σχεδόν πάντα έχουν δίκιο. Το Node2Vec εμφανίζει σημαντικά περισσότερα False Negatives (2.934), χάνει πραγματικές ακμές που οι τοπολογικές μέθοδοι εντοπίζουν εύκολα, εξηγώντας το χαμηλότερο Recall του.

### 5.2.3. Καμπύλη ROC (Receiver Operating Characteristic)

Για την οπτικοποίηση και σύγκριση της αποδοτικότητας των τριών μεθόδων, κατασκευάστηκε η καμπύλη ROC (Receiver Operating Characteristic), η οποία απεικονίζει τη σχέση μεταξύ του True Positive Rate (TPR) και του False Positive Rate (FPR) για κάθε δυνατό κατώφλι απόφασης (threshold).

Όπως φαίνεται στο κάτωθι γράφημα και οι τρεις μέθοδοι υπερέχουν σαφώς έναντι ενός τυχαίου ταξινομητή (διακεκομμένη διαγώνιος, AUC=0.50). Ο δείκτης Adamic-Adar επιτυγχάνει την υψηλότερη καμπύλη (AUC=0.9546), ακολουθούμενος από τον Jaccard (AUC=0.9488) και το Node2Vec (AUC=0.9273). Αξιοσημείωτο είναι ότι οι κλασικές μέθοδοι εμφανίζουν απότομη άνοδο του TPR για πολύ χαμηλές τιμές FPR, γεγονός που επιβεβαιώνει την υψηλή τους Precision στον εντοπισμό πραγματικών συνδέσμων.




*Πίνακας 3: Καμπύλες ROC για τη σύγκριση των μεθόδων πρόβλεψης συνδέσμων.*

### 5.2.4. Έλεγχος Υπερεκπαίδευσης

Για την αξιολόγηση της ικανότητας γενίκευσης του μοντέλου Node2Vec, πραγματοποιήθηκε σύγκριση της απόδοσης στο σύνολο εκπαίδευσης (train set) και στο ανεξάρτητο σύνολο ελέγχου (test set).

```
Train AUC: 0.9733
Test  AUC: 0.9273
Διαφορά:   4.61%
Δεν εντοπίστηκε υπερεκπαίδευση.
```

*Εικόνα 4: Αποτελέσματα ελέγχου υπερεκπαίδευσης*

Όπως παρατηρείται, η διαφορά μεταξύ του Train AUC (0.9747) και του Test AUC (0.9273) ανέρχεται σε 4.74%, κάτω από το όριο του 5% που συνήθως υποδηλώνει υπερεκπαίδευση. Το εύρημα αυτό επιβεβαιώνει ότι το μοντέλο δεν υπερεκπαιδεύτηκε — κατανόησε τα υποκείμενα μοτίβα και γενικεύει με επιτυχία σε εντελώς νέα, αόρατα δεδομένα. Η μικρή αυτή απόκλιση είναι απολύτως φυσιολογική για δίκτυο 36.692 κόμβων με χώρο αναπαράστασης 128 διαστάσεων.

### 5.2.5. Σχολιασμός Αποτελεσμάτων και Συσχέτιση με τη Δομή του Δικτύου

Από τη συγκριτική αξιολόγηση των μεθόδων προκύπτουν τα ακόλουθα συμπεράσματα για τη φύση του δικτύου Enron:

- Οι τοπολογικοί δείκτες Adamic-Adar και Jaccard επιτυγχάνουν τις υψηλότερες επιδόσεις, με το Precision να υπερβαίνει το 0.98. Η επικοινωνία στο δίκτυο τείνει να αναπτύσσεται μέσα σε κλειστές ομάδες συνεργατών, η ύπαρξη κοινών ατόμων ανάμεσα σε δύο υπαλλήλους αποτελεί έναν σχεδόν αλάνθαστο δείκτη για τη δημιουργία μελλοντικών συνδέσμων.
- Το Node2Vec, αν και επιτυγχάνει ένα πολύ ισχυρό AUC της τάξης του 0.9273, υπολείπεται ελαφρώς στις μετρικές Recall και F1-Score. Το Node2Vec υπερέχει στην κατανόηση της γενικής δομής διότι, σε αντίθεση με τους τοπολογικούς δείκτες που περιορίζονται σε άμεσες γειτονίες, εκμεταλλεύεται πληροφορία από περιπάτους 80 βημάτων. Αυτό επιτρέπει στο μοντέλο να κωδικοποιεί λανθάνουσες δομικές ιδιότητες των κόμβων, αποτυπώνοντας την οργανωτική θέση και τον ρόλο κάθε υπαλλήλου στο ευρύτερο δίκτυο, πέρα από τις τοπικές διασυνδέσεις. Η υψηλή τιμή AUC (0.9273) επιβεβαιώνει ότι το μοντέλο έχει επιτυχώς χαρτογραφήσει αυτές τις καθολικές ιδιότητες του δικτύου.
- Η υστέρηση στις τιμές Recall και Precision για το Node2Vec οφείλεται: για το Recall στο γεγονός ότι το Node2Vec, ως στοχαστική μέθοδος, δεν εντοπίζει πάντα τις ακμές που βασίζονται αποκλειστικά σε κλειστές τριάδες. Επειδή το μοντέλο μαθαίνει από τυχαίους περιπάτους, ενδέχεται να μην δώσει την απόλυτη προτεραιότητα σε συνδέσεις που είναι τοπικά προφανείς, με αποτέλεσμα να εμφανίζονται περισσότερες False Negatives. Για το Precision επειδή το μοντέλο προσπαθεί να μάθει τον γενικό ρόλο κάθε υπαλλήλου, μπορεί να προβλέψει συνδέσμους που είναι τοπολογικά λογικοί αλλά στην πραγματικότητα δεν υφίστανται στο dataset, αυξάνοντας τα False Positives.

Συνολικά, τα ευρήματα αναδεικνύουν ότι η επιλογή της βέλτιστης μεθόδου εξαρτάται από τον εκάστοτε στόχο: η ακρίβεια στον εντοπισμό άμεσων τοπικών συνεργασιών ευνοεί τους ευρετικούς δείκτες, ενώ η ανίχνευση λανθάνουσων οργανωτικών σχέσεων απαιτεί την εκφραστική δύναμη των embeddings.

## 6. Συμπεράσματα

Η παρούσα εργασία κατέδειξε ότι η ροή της πληροφορίας σε έναν μεγάλο οργανισμό, όπως η Enron, δεν είναι τυχαία, αλλά ακολουθεί τους αυστηρούς κανόνες των πολύπλοκων δικτύων «μικρού κόσμου» με κατανομή νόμου δύναμης (power-law). Βάσει αυτής της δομής, η πρόβλεψη της εταιρικής επικοινωνίας αποδείχθηκε απολύτως εφικτή, ωστόσο η επιλογή του κατάλληλου μοντέλου εξαρτάται από τα εκάστοτε κριτήρια αξιολόγησης και τους επιχειρησιακούς στόχους.

Για συστήματα που απαιτούν γρήγορη εξαγωγή αποτελεσμάτων με χαμηλό υπολογιστικό κόστος, οι κλασικές τοπολογικές μετρικές (όπως ο δείκτης Adamic-Adar) αποτελούν την ιδανική λύση. Η λειτουργία τους είναι απόλυτα διαφανής (π.χ. προβλέπουν μια σύνδεση επειδή υπάρχουν τρεις κοινοί συνεργάτες), προσφέροντας την υψηλότερη δυνατή Ακρίβεια (Precision) στον εντοπισμό άμεσων, τοπικών συνεργασιών.

Το μειονέκτημα των τοπολογικών δεικτών είναι ότι αποτυγχάνουν να προβλέψουν επικοινωνίες αν απουσιάζει η άμεση γειτνίαση. Εδώ ακριβώς αναδεικνύεται η δύναμη των σύγχρονων embeddings, όπως το Node2Vec. Αν και υστερεί σε

επεξηγησιμότητα (αποτελώντας ένα μαθηματικό "μαύρο κουτί" 128 διαστάσεων), παρουσιάζει κορυφαία ανθεκτικότητα (robustness) σε ελλιπή δεδομένα. Είναι σε θέση να ανακαλύψει λανθάνουσες (latent) σχέσεις και να προβλέψει επικοινωνίες που "δεν φαίνονται" άμεσα, βασιζόμενο στον ευρύτερο οργανωτικό ρόλο των υπαλλήλων μέσα στο δίκτυο.

Παρά τον αυξημένο χρόνο που απαιτείται για την εκπαίδευση του νευρωνικού δικτύου (εκτέλεση τυχαίων περιπάτων και βελτιστοποίηση), η αρχιτεκτονική του Node2Vec, ειδικά μέσω αποδοτικών υλοποιήσεων όπως η PecanPy, αποδεικνύεται εξαιρετικά κλιμακώσιμη (scalable), επιτρέποντας την εφαρμογή της μεθοδολογίας σε ακόμη μεγαλύτερα και πιο πολύπλοκα εταιρικά σχήματα.

Συμπερασματικά, η βέλτιστη στρατηγική για την πρόβλεψη συνδέσμων δεν είναι μονοδιάστατη. Αν ο στόχος είναι η καταγραφή ξεκάθαρων, ιεραρχικών δομών εργασίας, οι ευρετικοί κανόνες κυριαρχούν. Αν όμως ο στόχος είναι η στρατηγική ανάλυση ανθρώπινου δυναμικού και η εύρεση αόρατων συνεργειών μεταξύ ανθρώπων που δεν γνωρίζονται αλλά έχουν παρόμοιο ρόλο, τα μοντέλα εκμάθησης αναπαραστάσεων αποτελούν το ισχυρότερο σύγχρονο εργαλείο στην ανάλυση δικτύων.

## 7. Περιορισμοί και Παραδοχές της Ανάλυσης

Η παρούσα ερευνητική προσέγγιση, αν και αποδείχθηκε εξαιρετικά αποτελεσματική βάσει των μετρικών αξιολόγησης, υπόκειται σε συγκεκριμένους περιορισμούς που πηγάζουν τόσο από τη φύση των δεδομένων όσο και από τη μεθοδολογία ελέγχου.
Το σύνολο δεδομένων που χρησιμοποιήθηκε αποτελεί μια προεπεξεργασμένη μορφή του Enron Email Dataset (Edge List), από την οποία απουσιάζουν τα χρονικά δεδομένα της κάθε επικοινωνίας. Ως εκ τούτου, η ανάλυση πραγματοποιήθηκε με στατικό τρόπο. Αυτό σημαίνει ότι ο αλγόριθμος εκπαιδεύτηκε να εντοπίζει κρυμμένους συνδέσμους σε ένα σταθερό στιγμιότυπο του δικτύου, και όχι να προβλέπει τη μελλοντική εξέλιξη αυτού, κάτι που θα απαιτούσε χρονολογικό διαχωρισμό. Ωστόσο, η στατική αυτή παραδοχή είναι απολύτως συμβατή τόσο με την εκμάθηση αναπαραστάσεων (Node2Vec) όσο και με τη χρήση των ευρετικών δεικτών Jaccard και Adamic-Adar, οι οποίοι αξιολογούν τη δομική συγγένεια των κόμβων αποκλειστικά βάσει της τοπολογίας τους. Η συγκριτική αξιολόγηση των τριών μοντέλων βασίστηκε σε σημειακές εκτιμήσεις των μετρικών πάνω στο ανεξάρτητο σύνολο ελέγχου. Για την επιβεβαίωση της στατιστικής σημαντικότητας των διαφορών εφαρμόστηκε το DeLong's test για τη σύγκριση των δύο κορυφαίων στρατηγικών Node2Vec (HighExploration vs BFS), αποκαλύπτοντας στατιστικά σημαντική διαφορά ($Z=5.82$, $p<0.001$). Για τη σύγκριση μεταξύ των τριών κύριων μεθόδων (Jaccard, Adamic-Adar, Node2Vec) η εφαρμογή τέτοιων ελέγχων αφήνεται ως περιθώριο για μελλοντική μελέτη

## 8. Προτάσεις για Μελλοντική Έρευνα

Βασιζόμενοι στα συμπεράσματα και τους περιορισμούς της παρούσας μελέτης, αναδεικνύονται ενδιαφέρουσες κατευθύνσεις για την περαιτέρω εξέλιξη της έρευνας γύρω από την πρόβλεψη συνδέσμων σε εταιρικά δίκτυα.

Η ενσωμάτωση της χρονικής διάστασης (timestamps) των emails θα επέτρεπε τη μετάβαση από τη στατική ανάλυση στη δυναμική. Η χρήση μοντέλων που σχεδιάστηκαν για χρονικά γραφήματα θα καθιστούσε δυνατή όχι μόνο την πρόβλεψη του αν θα υπάρξει επικοινωνία μεταξύ δύο υπαλλήλων, αλλά και του πότε αυτή θα συμβεί, αποτυπώνοντας την εξέλιξη των εταιρικών project στον χρόνο.
Η παρούσα προσέγγιση βασίστηκε αποκλειστικά στη δομική τοπολογία του δικτύου. Μια μελλοντική επέκταση θα ήταν η χρήση Νευρωνικών Δικτύων Γράφων (Graph Neural Networks - GNNs), όπως οι δημοφιλείς αρχιτεκτονικές GCN και GraphSAGE, οι οποίες μπορούν να συνδυάσουν την τοπολογία τα οποία μπορούν να συνδυάσουν την τοπολογία με επιπλέον χαρακτηριστικά των κόμβων. Τέτοια χαρακτηριστικά θα μπορούσαν να είναι ο επίσημος ρόλος του υπαλλήλου (π.χ. Manager, CEO), το τμήμα του και η ανάλυση συναισθήματος πάνω στο ίδιο το κείμενο των emails μέσω τεχνικών Επεξεργασίας Φυσικής Γλώσσας (NLP).
Η επέκταση του μοντέλου ώστε να λαμβάνει υπόψη τη συχνότητα της επικοινωνίας (βάρος ακμής) και την κατεύθυνσή της (ποιος στέλνει σε ποιον) θα μπορούσε να αποκαλύψει βαθύτερα ιεραρχικά μοτίβα. Για παράδειγμα, η ασύμμετρη επικοινωνία (όπου ο Α στέλνει πολλά μηνύματα στον Β, αλλά λαμβάνει λίγα) συχνά υποδηλώνει σχέσεις αναφοράς (reporting lines), πληροφορία που θα αύξανε κατακόρυφα την ακρίβεια των προβλέψεων.

## 9. Βιβλιογραφία & Αναφορές


Φιλιππάκης Μ., Χαλκίδη Μ. (2026). *Εξόρυξη και Ανάλυση Δεδομένων.* [Σημειώσεις παραδόσεων]. Τμήμα Ψηφιακών Συστημάτων, Πανεπιστήμιο Πειραιώς.

Grover, A., & Leskovec, J. (2016). node2vec: Scalable feature learning for networks. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 855–864. https://doi.org/10.1145/2939672.2939754

Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. *Proceedings of the 7th Python in Science Conference*, 11–15. https://networkx.org/

Leskovec, J., Rajaraman, A., & Ullman, J. D. (2014). *Mining of massive datasets* (2nd ed.). Cambridge University Press. http://infolab.stanford.edu/~ullman/mmds.html

NetworkX Developers. (2026). *NetworkX tutorial.* NetworkX Documentation. Ανακτήθηκε στις 7 Μαΐου 2026, από https://networkx.org/documentation/stable/tutorial.html

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://scikit-learn.org/

Řehůřek, R., & Sojka, P. (2010). Software framework for topic modelling with large corpora. *Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks*, 45–50. https://radimrehurek.com/gensim/

Stanford Network Analysis Project. (n.d.). *Enron email network.* Stanford University. Ανακτήθηκε στις 7 Μαΐου 2026, από https://snap.stanford.edu/data/email-Enron.html